pandas类库API帮助文档：

https://pandas.pydata.org/pandas-docs/stable/reference/frame.html

数据创建

df=pd.DataFrame(np.random.rand(10,5)) # 创建一个5列10行的由随机浮点数组成的数据框 DataFrame df = pd.DataFrame({'A':np.array([1,np.nan,2,3,6,np.nan]), 'B':np.array([np.nan,4,np.nan,5,9,np.nan]), 'C':'foo'}, index=[4, 5, 6, 7]) # 创建一个5列10行的指定值组成的数据框 DataFrame,索引从4~7 pd.Series(my_list) # 从一个可迭代的对象 my_list 中创建一个数据组 df.index = pd.date_range('2017/1/1', periods=df.shape[0]) # 添加一个日期索引 index

数据的查看与检查

df.head(n) # 查看数据框的前n行 df.tail(n) # 查看数据框的最后n行 df.shape # 查看数据框的行数与列数 df.info() # 查看数据框 (DataFrame) 的索引、数据类型及内存信息 df.describe() # 对于数据类型为数值型的列，查询其描述性统计的内容 s = pd.Series([1,2,3,3,4,np.nan,5,5,5,6,7]) s.value_counts(dropna=False) # 查询每个独特数据值出现次数统计 df.apply(pd.Series.value_counts) # 查询数据框 (Data Frame) 中每个列的独特数据值出现次数统计 DataFrame.nunique(self, axis=0, dropna=True)

数据的选取

df[col] # 以数组 Series 的形式返回选取的列 df[[col1, col2]] # 以新的数据框(DataFrame)的形式返回选取的列 s = pd.Series(np.array(['I','Love','Data'])) s.iloc[0] # 按照位置选取 s.loc[] # 按照索引选取 df.iloc[0,:] # 选取第一行 df.iloc[0,0] # 选取第一行的第一个元素

数据的清洗（更改）

df.columns = ['a','b','c','d','e'] # 重命名数据框的列名称 df.rename(columns=lambda x: x + 2) # 将全体列重命名 df.rename(columns={'old_name': 'new_ name'}) # 将选择的列重命名 df.set_index('column_one') # 改变索引见下 df.rename(index = lambda x: x+ 1) # 改变全体索引 pd.isnull() # 检查数据中空值出现的情况，并返回一个由布尔值(True,False)组成的列 pd.notnull() # 检查数据中非空值出现的情况，并返回一个由布尔值(True,False)组成的列 df.dropna() # 移除数据框 DataFrame 中包含空值的行 df.dropna(axis=1) # 移除数据框 DataFrame 中包含空值的列 df.fillna(x) # 将数据框 DataFrame 中的所有空值替换为 x s.fillna(s.mean()) # 将所有空值替换为平均值 s.astype(float) # 将数组(Series)的格式转化为浮点数 s.replace(1,'one') # 将数组(Series)中的所有1替换为'one' s.replace([1,3],['one','three']) # 将数组(Series)中所有的1替换为'one', 所有的3替换为'three'

set_index

DataFrame可以通过set_index方法，可以设置单索引和复合索引。
DataFrame.set_index(keys, drop=True, append=False, inplace=False, verify_integrity=False)
append添加新索引，drop为False，inplace为True时，索引将会还原为列

In [307]: data Out[307]: a b c d 0 bar one z 1.0 1 bar two y 2.0 2 foo one x 3.0 3 foo two w 4.0 In [308]: indexed1 = data.set_index('c') In [309]: indexed1 Out[309]: a b d c z bar one 1.0 y bar two 2.0 x foo one 3.0 w foo two 4.0 In [310]: indexed2 = data.set_index(['a', 'b']) In [311]: indexed2 Out[311]: c d a b bar one z 1.0 two y 2.0 foo one x 3.0 two w 4.0

reset_index

data.reset_index()

数据的过滤(filter),排序(sort)和分组(groupby)

df[df[col] > 0.5] # 选取数据框df中对应行的数值大于0.5的全部列 df[(df[col] > 0.5) & (df[col] < 0.7)] # 选取数据框df中对应行的数值大于0.5，并且小于0.7的全部列 df.sort_values(col1) # 按照数据框的列col1升序(ascending)的方式对数据框df做排序 df.sort_values(col2,ascending=False) # 按照数据框的列col2降序(descending)的方式对数据框df做排序 df.sort_values([col1,col2],ascending=[True,False]) # 先按照数据框的列col1升序，再col2降序的方式对数据框df做排序 df.groupby(col) # 按照某列对数据框df做分组 df.groupby('A').count() ######按分组进行=》统计 df.groupby([col1,col2]) # 按照列col1和col2对数据框df做分组 df.groupby(['B','C']).sum() #######同上分组，对结果的数值列求和 df.groupby(col1)[col2].mean() # 按照列col1对数据框df做分组处理后，返回对应的col2的平均值 df.pivot_table(index=col1,values=[col2,col3],aggfunc=mean) # 做透视表，索引为col1,针对的数值列为col2和col3，分组函数为平均值

数据透视表：

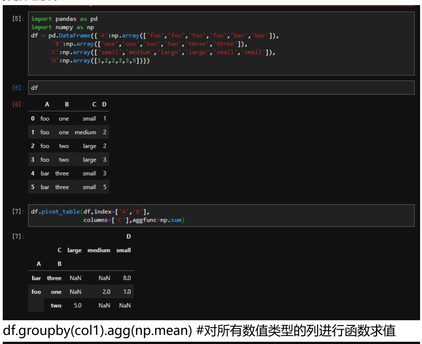

df.groupby(col1).agg(np.mean) #对所有数值类型的列进行函数求值

##========所有列都是数值类型是前提： df.apply(np.mean) # 对数据框df的每一列求平均值
df.apply(np.max,axis=1) # 对数据框df的每一行求最大值

数据（不是DataFrame）的连接(join)与组合(combine)

df1.append(df2) # 在数据框df2的末尾添加数据框df1，其中df1和df2的列数必须相等 pd.concat([df1, df2],axis=1) # 在数据框df1的列最后添加数据框df2,其中df1和df2的行数可以不相等

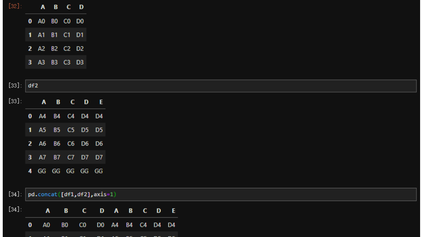

df1.join(df2,on=col1,how='inner') # 对数据框df1和df2做内连接，其中连接的列为col1 #如果要使用键列进行联接，则需要将key设置为df和other的索引。加入的DataFrame将具有键作为其索引。 >>> df.set_index('key').join(other.set_index('key')) A B key K0 A0 B0 K1 A1 B1 K2 A2 B2 K3 A3 NaN K4 A4 NaN K5 A5 NaN

数据的统计

df.describe() # 得到数据框df每一列的描述性统计 df.mean() # 得到数据框df中每一列的平均值 df.corr() # 得到数据框df中每一列与其他列的相关系数 df.count() # 得到数据框df中每一列的非空值个数 df.median() # 得到数据框df中每一列的中位数 df.std() # 得到数据框df中每一列的标准差 #其他。。。略 df['diff'].sum()